

1. Najlepsze modele:

- a. Modele z konfiguracją funkcji aktywacji "Tanh" w pierwszej warstwie oraz "ReLU" w drugiej osiągały wysokie wyniki walidacyjne, co wskazuje na skuteczną kombinację tych funkcji aktywacji.
- b. Learning rate na poziomie 0.01 był kluczowym czynnikiem poprawy wyników w porównaniu do 0.001.

2. Histogram liczby epok treningowych:

- a. Najczęściej najlepsze modele wymagały od 60 do 100 epok, co wskazuje, że sieć zbiega do optymalnego rozwiązania stosunkowo szybko.
- b. Modele z dużą liczbą epok (>150) mogą wskazywać na wolniejszą zbieżność lub potencjalne przeuczenie.

3. Wpływ funkcji aktywacji:

- a. Pierwsza warstwa: Funkcja "Tanh" generalnie zapewniała wyższą dokładność walidacyjną w porównaniu do "ReLU".
- b. Druga warstwa: Tutaj "ReLU" przewyższała "Tanh", co wskazuje na jej skuteczność w warstwach głębszych.

4. Wpływ liczby neuronów:

- a. W pierwszej warstwie większa liczba neuronów (16) prowadziła do lepszej dokładności walidacyjnej w porównaniu do mniejszej liczby (8).
- b. W drugiej warstwie liczba neuronów 8 była bardziej skuteczna w poprawie wyników walidacyjnych niż 4.

5. Najgorsze modele:

- a. Najgorsze wyniki walidacyjne były związane z użyciem "Tanh" w obu warstwach i niskim współczynnikiem uczenia (0.001).
- b. Modele z niską liczbą neuronów (np. 4) i funkcją aktywacji "ReLU" w obu warstwach również wykazywały słabe wyniki.

6. Wpływ współczynnika uczenia:

- a. Modele z współczynnikiem uczenia 0.01 przewyższały te z 0.001, co wskazuje na lepszą zdolność do szybkiej zbieżności przy wyższym learning rate.

Podsumowanie:

• Optymalna konfiguracja:

- Learning rate: 0.01.
- Funkcja aktywacji: "Tanh" w pierwszej warstwie, "ReLU" w drugiej.
- Liczba neuronów: 16 w pierwszej warstwie, 8 w drugiej.
- Epoki: 60–100 dla szybkiej zbieżności bez przeuczenia.